



VILNIUS UNIVERSITY
FACULTY OF MATHEMATICS AND INFORMATICS
INFORMATIKOS

Ataskaita

Kietųjų dalelių koncentracijos prognozavimas laiko eilutėse

Duomenų paruošimas

Mindaugas Žiemys

Vilnius
2026

Turinys

1. Duomenų paruošimas	3
1.1. CO pašalinimas	3
1.2. COVID–19 pandemijos 2020–2022 m. laikotarpio pašalinimas	3
1.3. Neigiamų reikšmių pašalinimas	4
1.4. Eilučių su trūkstamomis reikšmėmis pašalinimas	4
1.5. Vėjo krypties sin ir cos dedamųjų pridėjimas.	5
1.6. Dienos kategorijos sukūrimas	5
1.7. Sezoniniai teršalų trendai	5
1.8. Min-max normalizavimas	6
2. Rezultatai	8
2.1. Validžių duomenų iškarpa	8
2.2. Iškarpa su nevalidžiais duomenimis	9
2.3. Valandų blokų filtravimas	9

1. Duomenų paruošimas

Pradinis duomenų rinkinys apima 2012–2025 metų valandinius oro taršos matavimus iš Londo-
no Merilebono kelio stoties – iš viso 122 736 eilutės. Duomenų paruošimo seką apima šie pagrindiniai žingsniai:

- CO stulpelio pašalinimas.
- COVID–19 pandemijos 2020–2022 m. laikotarpio pašalinimas.
- Neigiamų reikšmių pašalinimas.
- Eilučių su trūkstamomis reikšmėmis pašalinimas.
- Vėjo krypties sin ir cos dedamųjų pridėjimas.
- Dienos kategorijos stulpelio sukūrimas.
- Min-Max normalizavimas – verčių perkėlimas į intervalą $[-1, 1]$.

1.1. CO pašalinimas

Iš visų 122 736 eilučių, 30 770 (25,1 %) turi bent vieną trūkstamą reikšmę. 1 lentelėje pateikiamas eilučių su trūkstamomis reikšmėmis kiekis ir jų dalis, skaičiuojama nuo viso pradinio duomenų rinkinio ($N = 122\,736$).

1 lentelė. Trūkstamos reikšmės pagal atributą ($N = 122\,736$)

Atributas	Kiekis	Dalis (%)
CO	12 704	10,35
KD ₁₀	10 379	8,46
KD _{2,5}	9 649	7,86
O ₃	4 359	3,55
NO	3 653	2,98
NO ₂	3 653	2,98
Vėjo greitis	3 168	2,58
Temperatūra	3 168	2,58
Vėjo kryptis	3 168	2,58

CO turi didžiausią trūkstamų reikšmių dalį (10,35 %). Dėl šių priežasčių CO pašalintas iš duomenų rinkinio. Pašalinus CO, eilučių su trūkstamomis reikšmėmis liko 21 636 (17,6 %).

1.2. COVID–19 pandemijos 2020–2022 m. laikotarpio pašalinimas

Sprendimą pašalinti šio laikotarpio duomenis lėmė dvi priežastys. Pirma, COVID–19 pandemijos metu dėl taikytų ribojimų oro taršos tendencijos buvo netipiškos. Antra, šiuo laikotarpiu fiksuotas žymiai didesnis KD_{2,5} duomenų trūkumas (žr. 2 lentelę).

2 lentelė. Vidutinis trūkstamų $KD_{2,5}$ reikšmių kiekis ir dalis per metus

Laikotarpis	Kiekis (vid.)	Dalis (%)
2012–2019 m.	483	5,51
2020–2022 m. (Pandeminis)	1 476	16,84
2023–2025 m.	436	4,97

Pašalinus COVID–19 laikotarpio įrašus, pilnas duomenų rinkinį sudaro 96 432 įrašai, iš jų 13 875 (14,4%) – turi bent vieną trūkstamą reikšmę.

1.3. Neigiamų reikšmių pašalinimas

Kadangi koncentracija fiziškai negali būti mažesnė už nulį, tokie duomenys laikomi matavimo įrangos paklaidomis ir yra pašalinami.

3 lentelė. Teršalų koncentracijų ribinės reikšmės ir neigiamų įrašų kiekis

Atributas	Min	Max	Neigiamų kiekis
O ₃	–0,93	156,46	22
NO	–0,37	872,83	9
PM ₁₀	–2,90	187,90	44
PM _{2,5}	–5,00	127,60	280
NO ₂	0,00	321,91	0
Iš viso	–	–	355

Pašalinus neigiamas reikšmes, duomenų rinkinį sudaro 96 211 įrašai, iš jų 13 855 (14,4%) – turi bent vieną trūkstamą reikšmę.

1.4. Eilučių su trūkstamomis reikšmėmis pašalinimas

Analizė parodo, kad 69,1% visų duomenų spragų (žr. 4 lentelę) sudaro laikotarpiai, ilgesni nei 24 val.

4 lentelė. Įrašų su trūkstamomis reikšmėmis pasiskirstymas pagal trukmę

Tarpo ilgis	Eilučių kiekis	Dalis (%)
1 val.	470	3,4
2 val.	301	2,2
3–5 val.	322	2,3
6–12 val.	573	4,1
12–24 val.	2 612	18,9
24+ val.	9 577	69,1
Iš viso	13 855	100,0

Visos eilutės su trūkstamomis reikšmėmis yra pašalinamos. Pašalinus trūkstamus įrašus, pilną duomenų rinkinį sudaro 82 356 įrašai.

1.5. Vėjo krypties sin ir cos dedamųjų pridėjimas.

Vėjo kryptis (laipsniais, 0–360°) konvertuota į dvi dedamąsias: sinusą ir kosinusą:

$$s = \sin\left(\alpha \cdot \frac{\pi}{180}\right), \quad c = \cos\left(\alpha \cdot \frac{\pi}{180}\right) \quad (1)$$

Trigonometrinės funkcijos sin ir cos naudojamos su radianų argumentais, todėl vėjo krypties matavimai laipsniais (α) konvertuojami taikant $\pi/180$.

Transformavimas į sin ir cos išsprendžia cikliškumo problemą. Kampai 0° ir 360° yra identiški, tačiau skaitiškai skiriasi: $|360 - 0| = 360$, nors faktinis skirtumas 0°. Sinuso ir kosinuso atvaizdavime šie kampai duoda identiškas reikšmių poras. Originalus vėjo krypties stulpelis pašalintas.

1.6. Dienos kategorijos sukūrimas

Kiekviena laiko eilutė susieta su dienos kategorija, kurią galima aprašyti:

$$\text{kategorija}(d) = \begin{cases} 1, & \text{jei } d \text{ yra poilsio diena} \\ 2, & \text{jei } d + 1 \text{ yra poilsio diena} \\ 0, & \text{kitais atvejais (darbo diena)} \end{cases} \quad (2)$$

čia poilsio diena – savaitgalis (šeštadienis arba sekmadienis) arba JK valstybinė šventė. Dienos kategorija bus naudojamas kaip filtras – prognozei naudojami įrašai apribojami tik tais įrašais, kurie priklauso tai pačiai kategorijai. Tokiu būdu užtikrinama, kad, pavyzdžiui, sekmadienio tarša nebūtų prognozuojama remiantis pirmadienio duomenimis, nes transporto intensyvumas šiomis dienomis skiriasi.

1.7. Sezoniniai teršalų trendai

5 lentelėje pateikiami pagrindinių teršalų mėnesiniai vidurkiai. Sausio – kovo mėn. vidutinė $KD_{2,5}$ koncentracija išauga. NO koncentracija padidėja lapkričio – sausio mėn.

5 lentelė. Teršalų vidutinės mėnesinės koncentracijos ($\mu\text{g}/\text{m}^3$)

Mėnuo	O ₃	NO	NO ₂	KD ₁₀	KD _{2,5}
Sausis	15,25	122,16	76,36	26,67	17,08
Vasaris	18,50	108,38	72,93	27,38	17,82
Kovas	23,71	92,03	73,72	29,23	19,99
Balandis	30,55	81,20	72,36	25,27	16,63
Gegužė	32,42	75,45	68,53	22,69	15,11
Birželis	27,13	87,40	72,36	20,49	13,16
Liepa	22,48	88,32	72,83	19,62	12,91
Rugpjūtis	20,33	83,07	68,15	21,05	12,94
Rugsėjis	18,00	95,17	70,47	22,46	14,94
Spalis	14,60	108,68	71,47	23,83	14,58
Lapkritis	13,09	121,73	71,55	25,44	15,77
Gruodis	16,03	122,40	73,90	24,31	15,03

Sezoniniai skirtumai rodo, kad modelio prognozavimui įtaką gali turėti sezoniškumas. Sezoniskumas bus įtrauktas į K-NN metodą, apribojant paiešką ± 20 dienų tolerancijos intervalu aplink tikslinę datą, per visų turimų metų duomenų rinkinį. Pavyzdžiui, prognozuojant 2023 m. rugpjūčio 2 d. taršą, paieška apima visų metų laikotarpius nuo liepos 13 d. iki rugpjūčio 22 d.

1.8. Min-max normalizavimas

Skaitiniai matavimų atributai normalizuoti į $[-1, 1]$ intervalą pagal formulę:

$$x' = \frac{2(x - x_{\min})}{x_{\max} - x_{\min}} - 1 \quad (3)$$

čia x – originali reikšmė, $x_{\min}$ ir $x_{\max}$ – atitinkamo atributo minimali ir maksimali reikšmės vi-soje duomenų aibėje, x' – normalizuota reikšmė. Normalizavimas atliekamas kiekvienam atributui atskirai, naudojant tik jam būdingas minimalias ir maksimalias reikšmes. Tokiu būdu visų kintamųjų vertės suvienodinamas iki $[-1, 1]$ intervalo.

6 lentelėje pateikiamos normalizuojamų atributų minimalios ir maksimalios reikšmės. Neigiamos minimalios reikšmės buvo pašalintos praeitame žingsnyje.

6 lentelė. Atributų minimalios ir maksimalios reikšmės, naudojamos normalizavimui

Atributas	Vnt.	$x_{\min}$	$x_{\max}$
O ₃	$\mu\text{g}/\text{m}^3$	0,00	151,47
NO	$\mu\text{g}/\text{m}^3$	0,00	872,83
NO ₂	$\mu\text{g}/\text{m}^3$	0,00	321,91
KD ₁₀	$\mu\text{g}/\text{m}^3$	0,00	187,90
KD _{2,5}	$\mu\text{g}/\text{m}^3$	0,00	127,60
Vėjo greitis	m/s	0,00	13,70
Temperatūra	°C	-10,50	33,40

Vėjo krypties sinuso ir kosinuso komponentai nebuvo normalizuoti papildomai, nes pagal apibrėžimą jau patenka į $[-1, 1]$ intervalą. Dienos kategorija ir valanda yra kategoriniai atributai, jų normalizuoti nereikia.

2. Rezultatai

2.1. Validžių duomenų iškarpa

Lentelėje 7 pateikiama validžių originalių duomenų iškarpa prieš normalizavimą.

7 lentelė. Validžių originalių duomenų iškarpa

Data	Laikas	O ₃	NO	NO ₂	CO	KD ₁₀	KD _{2,5}	Vėjo krypt.	Vėjo greit.	Temp.
2016-03-30	06:00:00	3,79	289,29	134,73	0,595	31,9	14,17	246,8	2,6	1,6
2016-03-30	07:00:00	2,94	404,42	160,86	0,863	35,2	16,35	253,6	3,5	3,4
2016-03-30	08:00:00	3,04	442,75	169,61	0,952	35,4	16,95	257,8	3,5	6,2
2016-03-30	09:00:00	3,44	455,46	194,32	0,833	45,0	18,23	264,3	4,2	8,5
2016-03-30	10:00:00	5,09	391,30	167,55	0,862	43,9	16,95	270,5	4,8	10,0
2016-03-30	11:00:00	9,08	231,78	138,45	0,595	27,7	11,00	266,9	4,6	11,0
2016-03-30	12:00:00	7,28	282,47	148,30	0,714	37,1	16,25	267,2	4,3	11,8
2016-03-30	13:00:00	8,68	265,75	139,28	0,535	32,4	16,25	259,4	4,3	12,0
2016-03-30	14:00:00	12,27	159,92	104,98	0,417	19,3	8,92	255,7	4,2	11,7
2016-03-30	15:00:00	13,02	164,73	108,93	0,476	20,5	10,21	252,9	3,7	11,1
2016-03-30	16:00:00	12,17	182,46	135,16	0,684	28,4	10,60	256,4	3,3	10,4
2016-03-30	17:00:00	7,83	279,46	141,91	0,952	30,4	13,58	250,0	1,8	9,2
2016-03-30	18:00:00	13,32	145,24	114,01	0,595	22,1	12,49	227,0	1,8	7,5

Lentelėje 8 pateikiama šios iškarpos normalizuota ir transformuota versija.

8 lentelė. Validžių normalizuotų ir transformuotų duomenų škarpa

Data	Val.	O ₃	NO	NO ₂	KD ₁₀	KD _{2,5}	Vėjo gr.	Temp.	Dienos kat.	Vėjo sin	Vėjo cos
2016-03-30	6	-0,94	-0,34	-0,16	-0,66	-0,78	-0,62	-0,45	0	-0,92	-0,39
2016-03-30	7	-0,95	-0,07	0,00	-0,63	-0,74	-0,49	-0,37	0	-0,96	-0,28
2016-03-30	8	-0,95	0,01	0,05	-0,62	-0,73	-0,49	-0,24	0	-0,98	-0,21
2016-03-30	9	-0,94	0,04	0,21	-0,52	-0,71	-0,39	-0,13	0	-1,00	-0,10
2016-03-30	10	-0,92	-0,10	0,04	-0,53	-0,73	-0,30	-0,07	0	-1,00	0,01
2016-03-30	11	-0,85	-0,47	-0,14	-0,71	-0,83	-0,33	-0,02	0	-1,00	-0,05
2016-03-30	12	-0,88	-0,35	-0,08	-0,61	-0,75	-0,37	0,02	0	-1,00	-0,05
2016-03-30	13	-0,86	-0,39	-0,13	-0,66	-0,75	-0,37	0,03	0	-0,98	-0,18
2016-03-30	14	-0,80	-0,63	-0,35	-0,79	-0,86	-0,39	0,01	0	-0,97	-0,25
2016-03-30	15	-0,79	-0,62	-0,32	-0,78	-0,84	-0,46	-0,02	0	-0,96	-0,29
2016-03-30	16	-0,80	-0,58	-0,16	-0,70	-0,83	-0,52	-0,05	0	-0,97	-0,24
2016-03-30	17	-0,87	-0,36	-0,12	-0,68	-0,79	-0,74	-0,10	0	-0,94	-0,34
2016-03-30	18	-0,78	-0,67	-0,29	-0,76	-0,80	-0,74	-0,18	0	-0,73	-0,68
2016-03-30	19	-0,68	-0,87	-0,46	-0,87	-0,91	-0,75	-0,24	0	-0,76	-0,65

2.2. Iškarpa su nevalidžiais duomenimis

Lentelėje 9 pateikiama duomenų iškarpa su trūkstamomis reikšmėmis 11, 12, 13 valandomis bei su neigiama $KD_{2,5}$ reikšme 6 valandą.

9 lentelė. Originalių duomenų iškarpa su trūkstamomis ir neigiamomis reikšmėmis

Data	Laikas	O ₃	NO	NO ₂	CO	KD ₁₀	KD _{2,5}	Vėjo krypt.	Vėjo greit.	Temp.
2023-08-02	06:00:00	6,79	27,94	15,30	0,140	7,73	-1,0	240,6	6,0	17,7
2023-08-02	07:00:00	8,18	32,31	19,13	0,198	10,63	1,0	246,1	6,0	17,7
2023-08-02	08:00:00	8,98	45,15	37,10	0,221	9,66	4,0	247,8	6,3	18,2
2023-08-02	09:00:00	16,56	43,03	41,12	0,221	7,73	4,0	241,9	6,6	19,0
2023-08-02	10:00:00	17,56	38,79	39,78	0,244	8,70	3,0	234,7	6,9	18,9
2023-08-02	11:00:00	NaN	NaN	NaN	NaN	9,66	6,0	225,6	5,5	16,5
2023-08-02	12:00:00	NaN	NaN	NaN	NaN	NaN	NaN	222,1	4,7	16,6
2023-08-02	13:00:00	10,58	50,52	51,26	0,256	NaN	NaN	223,2	4,8	16,8
2023-08-02	14:00:00	5,79	72,59	59,86	0,361	24,16	24,0	220,8	5,2	16,8
2023-08-02	15:00:00	6,98	51,01	54,51	0,303	7,73	7,0	204,2	4,0	17,9
2023-08-02	16:00:00	6,79	50,89	57,38	0,349	9,66	11,0	232,1	3,8	19,0
2023-08-02	17:00:00	16,76	16,96	37,29	0,210	6,76	6,0	260,0	2,7	18,5
2023-08-02	18:00:00	13,57	14,34	35,19	0,221	8,70	10,0	313,8	3,2	18,0

Lentelėje 10 pateikiama šios iškarpos išvalyta, normalizuota ir transformuota versija. 6 valanda buvo pašalinta dėl neigiamos $KD_{2,5}$ reikšmės, o valandos 11, 12, 13 – dėl trūkstamų reikšmių.

10 lentelė. Normalizuotų duomenų iškarpa su trūkstamomis ir neigiamomis reikšmėmis

Data	Val.	O ₃	NO	NO ₂	KD ₁₀	KD _{2,5}	Vėjo gr.	Temp.	Dienos kat.	Vėjo sin	Vėjo cos
2023-08-02	5	-0,82	-0,96	-0,89	-0,91	-0,95	-0,27	0,28	0	-0,88	-0,47
2023-08-02	7	-0,87	-0,93	-0,88	-0,89	-0,98	-0,12	0,28	0	-0,91	-0,41
2023-08-02	8	-0,85	-0,90	-0,77	-0,90	-0,94	-0,08	0,31	0	-0,93	-0,38
2023-08-02	9	-0,73	-0,90	-0,74	-0,92	-0,94	-0,04	0,34	0	-0,88	-0,47
2023-08-02	10	-0,71	-0,91	-0,75	-0,91	-0,95	0,01	0,34	0	-0,82	-0,58
2023-08-02	14	-0,91	-0,83	-0,63	-0,74	-0,62	-0,24	0,24	0	-0,65	-0,76
2023-08-02	15	-0,89	-0,88	-0,66	-0,92	-0,89	-0,42	0,29	0	-0,41	-0,91
2023-08-02	16	-0,89	-0,88	-0,64	-0,90	-0,83	-0,45	0,34	0	-0,79	-0,61
2023-08-02	17	-0,73	-0,96	-0,77	-0,93	-0,91	-0,61	0,32	0	-0,98	-0,17
2023-08-02	18	-0,78	-0,97	-0,78	-0,91	-0,84	-0,53	0,30	0	-0,72	0,69

2.3. Valandų blokų filtravimas

KNN modelio prognozavimui bus naudojami nepertraukiami penkių valandų įvesties ir dvylikos valandų prognozės blokai. Bus taikomas duomenų filtravimo kriterijus: jei pasirinktame laiko bloke (tiek įvesties, tiek prognozės lange) aptinkama bent viena trūkstama reikšmė, visas blokas yra pašalinamas iš tyrimo ir laikomas netinkamu analizei.