



VILNIUS UNIVERSITY
FACULTY OF MATHEMATICS AND INFORMATICS
INFORMATIKOS

Ataskaita

Kietųjų dalelių koncentracijos prognozavimas laiko eilutėse

Svertinio Euklido atstumo su svoriais metodika

Mindaugas Žiemys

Vilnius
2026

Turinys

1. Prognozavimo metodika	3
1.1. Atstumo funkcijos	3
1.2. Agreguotas svertinis atstumas	4
1.3. Paieškos erdvės apribojimai	4
1.4. Prognozavimo algoritmas ir baltosios dėžės principas	5
1.5. Pradinis slenksčio reikšmės parinkimas	5
1.6. Prognozės sudarymas	5
1.7. Modelio vertinimo kriterijai	6
1.8. Testavimo procesas	7

1. Prognozavimo metodika

Oro taršos prognozavimui naudojamas modifikuotas K artimiausių kaimynų (KNN) metodas su svoriais. Modelio esmė – rasti istorinius 5 valandų laikotarpius, kurių meteorologinės ir taršos sąlygos yra panašiausios į dabartinę situaciją, ir pagal jų tęsinį prognozuoti $KD_{2,5}$ koncentraciją ateinančioms 12 valandų.

Panašumui įvertinti naudojamas svertinis Euklido atstumas, sudarytas iš penkių atskirų atstumo funkcijų. Kiekviena funkcija apima tam tikrą atributų poaibį ir matuoja atstumą tarp dabartinio 5 valandų lango $\mathbf{x}$ ir istorinio lango $\mathbf{y}$. Funkcijoms priskiriami svorio koeficientai, o galutinis panašumas skaičiuojamas kaip svertinė suma.

1.1. Atstumo funkcijos

1 funkcija. Vėjo dinamika (d_1)

Apima vėjo greitį (v) ir vėjo krypties dedamąsias ($s = \sin \alpha$, $c = \cos \alpha$). Vėjas yra pagrindinis teršalų sklaidos horizontalioje kryptyje veiksnys. Iš viso Euklido atstumas skaičiuojamas per $3 \times 5 = 15$ matmenų.

$$d_1 = \sqrt{\sum_{h=1}^5 [(s_{x,h} - s_{y,h})^2 + (c_{x,h} - c_{y,h})^2 + (v_{x,h} - v_{y,h})^2]} \quad (1)$$

čia h – valandos indeksas 5 valandų įvesties lange ($h = 1, 2, 3, 4, 5$).

2 funkcija. Temperatūra (d_2)

Temperatūra veikia teršalų sklaidą vertikalioje kryptyje ir cheminių reakcijų greitį. Apima 5 temperatūros (T) matavimus.

$$d_2 = \sqrt{\sum_{h=1}^5 (T_{x,h} - T_{y,h})^2} \quad (2)$$

3 funkcija. Dujiniai teršalai (d_3)

Apima visus dujinius teršalus, išskyrus kietąsias daleles: O_3 , NO ir NO_2 koncentracijas. Iš viso: $3 \text{ atributai} \times 5 \text{ valandos} = 15$ reikšmių.

$$d_3 = \sqrt{\sum_{h=1}^5 [(O_{3x,h} - O_{3y,h})^2 + (NO_{x,h} - NO_{y,h})^2 + (NO_{2x,h} - NO_{2y,h})^2]} \quad (3)$$

4 funkcija. KD_{10} (d_4)

Apima 5 stambiųjų kietųjų dalelių KD_{10} matavimus.

$$d_4 = \sqrt{\sum_{h=1}^5 (KD_{10x,h} - KD_{10y,h})^2} \quad (4)$$

5 funkcija. $KD_{2,5}$ dabartinis lygis (d_5)

Apima 5 tikslinio kintamojo $KD_{2,5}$ matavimus. Užtikrina, kad rastas kaimynas turėtų panašų dabartinį $KD_{2,5}$ lygį.

$$d_5 = \sqrt{\sum_{h=1}^5 (KD_{2,5x,h} - KD_{2,5y,h})^2} \quad (5)$$

1.2. Agreguotas svertinis atstumas

Visos penkios funkcijos apjungiamos į vieną svertinę sumą:

$$D(x, y) = w_1 d_1 + w_2 d_2 + w_3 d_3 + w_4 d_4 + w_5 d_5 \quad (6)$$

čia w_j – svorio koeficientai, tenkinantys sąlygą $\sum_{j=1}^5 w_j = 1$. Svoriai leidžia reguliuoti kiekvienos funkcijos įtaką bendram panašumui. Pradiniuose eksperimentuose visiems svoriams bus priskirta vienoda reikšmė $w_j = 0,2$. Optimalūs svoriai bus parinkti optimizavimo būdu, siekiant minimizuoti prognozės paklaidą.

1.3. Paieškos erdvės apribojimai

Potencialių kaimynų paieška istoriniuose duomenyse apribojama šiais filtrais:

- **Laiko sinchronizacija:** lyginami tik tie istoriniai langai, kurie prasideda tą pačią paros valandą kaip ir dabartinė situacija. Pavyzdžiui, jei dabartinis langas apima 8–12 val., istoriniai langai taip pat turi prasidėti nuo 8 iki 12 val.
- **Dienos kategorija:** langai lyginami pagal dienos kategoriją – darbo dienos su darbo dienomis, savaitgaliai su savaitgaliais, prieššventinės dienos su prieššventinėmis dienomis.
- **Sezoniškumas:** paieška apribojama ± 20 dienų intervalu aplink tikslinę datą per visus turimus metus. Pavyzdžiui, prognozuojant rugpjūčio 2 d. taršą, paieška apima laikotarpį nuo liepos 13 d. iki rugpjūčio 22 d. visais turimais metais.
- **Duomenų vientisumas:** įtraukiami tik tie blokai, kuriuose nėra trūkių nei 5 valandų įvesties, nei 12 valandų prognozės lange. Pavyzdžiui, jei istorinis langas prasideda 8 val., tai visos įvesties reikšmės nuo 8 iki 12 val. ir prognozės nuo 13 iki 24 val. turi būti be trūkstančių reikšmių.

1.4. Prognozavimo algoritmas ir baltosios dėžės principas

Modelis remiasi baltosios dėžės principu – kaimynų atranka pagrįsta ne fiksuotu artimiausių kaimynų skaičiumi K , o slenksčio konstanta S . Prognozavimo procesas vykdomas pagal šį algoritmą:

1 algoritmas Taršos prognozavimo algoritmas

```
1: Kaimynai  $\leftarrow \emptyset$  {Pradėti nuo tuščios aibės}
2: for kiekvienas istorinis langas  $y$  do
3:   if langas  $y$  tenkina laiko, dienos, sezono ir duomenų vientisumo filtrus then
4:     Apskaičiuoti agreguotą atstumą  $D(x, y)$ 
5:     if  $D(x, y) \leq S$  then
6:       Kaimynai  $\leftarrow$  Kaimynai  $\cup \{y\}$ 
7:     end if
8:   end if
9: end for
10: if Kaimynai =  $\emptyset$  then
11:   return Prognozė negalima
12: else
13:   return Skaičiuoti prognozę pagal kaimynų vidurkį
14: end if
```

Jei po viso filtravimo proceso nerandamas nė vienas kaimynas, tenkinantis slenksčio sąlygą, modelis informuoja, kad prognozė negalima – istoriniuose duomenyse nėra pakankamai panašių 5 valandų langų. Tai esminis skirtumas nuo juodosios dėžės metodų (pvz., dirbtinių neuroninių tinklų), kurie prognozuoja visais atvejais, nepriklausomai nuo to, ar istoriniuose duomenyse egzistuoja pakankamai į x panašių istorinių pavyzdžių.

1.5. Pradinis slenksčio reikšmės parinkimas

Kadangi visi atributai normalizuoti į intervalą $[-1, 1]$, su vienodais svoriais $w_j = 0,2$ teorinis agreguoto atstumo maksimumas yra $D_{\max} \approx 5,78$.

Pradiniam eksperimentui pasirinktas slenkstis $S = 0,5$. Tai sudaro maždaug 8,6% nuo maksimalaus įmanomo atstumo. Tai pakankamai griežta, kad atrinkti kaimynai būtų panašūs į dabartinį langą x , ir pakankamai atlaidu, kad nepadarytų padengimo rodiklio C pernelyg mažu.

Po pirminio eksperimento slenksčio konstanta S bus parenkama naudojant optimizavimo algoritmą – ieškant balanso tarp prognozės tikslumo ir padengimo (dalies atvejų, kuriems modelis pateikia prognozę).

1.6. Prognozės sudarymas

Atrenkami visi kaimynai, tenkinantys sąlygą $D \leq S$. Galutinė 12 valandų $KD_{2,5}$ prognozė kiekvienam laiko žingsniui $t \in \{1, \dots, 12\}$ skaičiuojama kaip atrinktų kaimynų ateities reikšmių vidurkis:

$$\hat{y}_t = \frac{1}{K} \sum_{k=1}^K y_t^{(k)} \quad (7)$$

čia K – kaimynų, patenkančių į slenksčio zoną, skaičius, $y_t^{(k)}$ – k -ojo kaimyno užfiksuota $KD_{2,5}$ koncentracija po t valandų nuo atskaitos taško.

Skirtingai nuo klasikinio KNN metodo, kuriame K yra fiksuotas, šiame modelyje K kinta dinamiškai priklausomai nuo to, kiek istorinių langų tenkina slenksčio sąlygą.

1.7. Modelio vertinimo kriterijai

Modelio prognozavimo kokybei vertinti naudojama normalizuota vidutinė absoliučioji paklaida (angl. *Normalized Mean Absolute Error*, NMAE). Pirmiausia kiekvienai prognozuojamai valandai t apskaičiuojama normalizuota absoliučioji paklaida (NAE):

$$NAE_t = \frac{|y_t - \hat{y}_t|}{y_{\max} - y_{\min}} \times 100\% \quad (8)$$

čia y_t – tikroji $KD_{2,5}$ koncentracijos reikšmė t -ąją prognozuojamą valandą, $\hat{y}_t$ – atitinkama modelio prognozuota reikšmė, $y_{\max}$ ir $y_{\min}$ – maksimali ir minimali $KD_{2,5}$ reikšmės testinių duomenų rinkinyje.

NMAE gaunama išvedant NAE reikšmių vidurkį per H valandų:

$$NMAE_H = \frac{1}{H} \sum_{t=1}^H NAE_t \quad (9)$$

Šis paklaidos tipas leidžia paklaidą išreikšti procentais nuo galimo $KD_{2,5}$ reikšmių rėžio, todėl rezultatas yra lengvai interpretuojamas ir nepriklauso nuo skaitinių koncentracijos verčių. Modelio kokybei įvertinti naudojami trys kriterijai.

1 kriterijus. NMAE 12 valandų į priekį

Kiekvienam testiniam langui x , kuriam pateikta prognozė, apskaičiuojama NMAE per visas 12 valandų:

$$NMAE_{12}^{(x)} = \frac{1}{12} \sum_{t=1}^{12} NAE_t^{(x)} \quad (10)$$

Galutiniam įvertinimui skaičiuojamas vidutinis visų prognozuotų langų tikslumas (μ_{12}) ir standartinis nuokrypis (σ_{12}):

$$\mu_{12} = \frac{1}{N_{\text{prog}}} \sum_x NMAE_{12}^{(x)}, \quad \sigma_{12} = \sqrt{\frac{1}{N_{\text{prog}}} \sum_x \left(NMAE_{12}^{(x)} - \mu_{12} \right)^2} \quad (11)$$

2 kriterijus. NMAE 5 valandoms į priekį

Šis kriterijus leidžia įvertinti modelio tikslumą trumpesniame 5 valandų ateities laikotarpiui, nes artimesnės valandos prognozuojamos tiksliau nei tolimesnės – per 12 valandų meteorologinės sąlygos gali smarkiai pasikeisti. Kiekvienam testiniam langui x , kuriam pateikta prognozė, apskaičiuojama NMAE per pirmąsias 5 prognozuojamas valandas:

$$NMAE_5^{(x)} = \frac{1}{5} \sum_{t=1}^5 NAE_t^{(x)} \quad (12)$$

Galutiniam įvertinimui skaičiuojamas vidutinis visų prognozuotų langų tikslumas (μ_5) ir standartinis nuokrypis (σ_5):

$$\mu_5 = \frac{1}{N_{\text{prog}}} \sum_x NMAE_5^{(x)}, \quad \sigma_5 = \sqrt{\frac{1}{N_{\text{prog}}} \sum_x \left(NMAE_5^{(x)} - \mu_5 \right)^2} \quad (13)$$

3 kriterijus. Padengimas

Trečiasis kriterijus matuoja, kokiai daliai testinių duomenų modelis sugebėjo pateikti prognozę:

$$C = \frac{N_{\text{prog}}}{N_{\text{viso}}} \times 100\% \quad (14)$$

čia N_{prog} – testinių langų skaičius, kuriems buvo pateikta prognozė, N_{viso} – bendras testinių langų skaičius. Šis kriterijus yra reikalingas, nes vien tik žemos NMAE reikšmės nepakanka – jei modelis prognozuoja tik 1% atvejų, jis praktiškai nenaudingas, nepaisant galimo aukšto tikslumo.

1.8. Testavimo procesas

Modelio vertinimas atliekamas 2025 metų duomenyse, kurie nėra įtraukti į kaimynų paieškos erdvę. Per testinius duomenis einama slenkančiu langu vienos valandos žingsniu. Tokiu būdu modelis vertinamas analogiškai tikram naudojimo scenarijui, kai prognozė atnaujinama kas valandą.

Kiekvienai testinio rinkinio valandai t formuojamas dabartinis 5 valandų įvesties langas x , sudarytas iš valandų $[t - 4, t]$, ir 12 valandų tikrosios reikšmės y_{true} iš valandų $[t + 1, t + 12]$. Jei yra trūkstamų reikšmių – langas praleidžiamas. Likusiems langams vykdomas 2 algoritmas.

2 algoritmas Modelio vertinimo testiniame rinkinyje algoritmas

```
1: rezultatai5 ← ∅, rezultatai12 ← ∅
2: Nprog ← 0, Nviso ← 0
3: for kiekviena valanda  $t$  testiniame rinkinyje do
4:    $x \leftarrow \text{duomenys}[t - 4 : t]$  {5 valandų įvestis (paskutinė valanda —  $t$ )}
5:    $y_{\text{true}} \leftarrow \text{duomenys}[t + 1 : t + 12]$  {12 valandų tikrovė}
6:   if  $x$  ir  $y_{\text{true}}$  tenkina duomenų vientisumo sąlygą then
7:     Nviso ← Nviso + 1
8:     Kaimynai ← ∅
9:     for kiekvienas istorinis langas  $y$  do
10:      if langas  $y$  tenkina laiko, dienos, sezono ir duomenų vientisumo filtrus then
11:        Apskaičiuoti agreguotą atstumą  $D(x, y)$ 
12:        if  $D(x, y) \leq S$  then
13:          Kaimynai ← Kaimynai ∪ { $y$ }
14:        end if
15:      end if
16:    end for
17:    if Kaimynai ≠ ∅ then
18:      Nprog ← Nprog + 1
19:       $\hat{y} \leftarrow$  kaimynų ateities reikšmių vidurkis pagal lygtį (7)
20:      Apskaičiuoti  $NMAE_5^{(x)}$  ir  $NMAE_{12}^{(x)}$  pagal lygtis (12) ir (10)
21:      rezultatai5 ← rezultatai5 ∪ { $NMAE_5^{(x)}$ }
22:      rezultatai12 ← rezultatai12 ∪ { $NMAE_{12}^{(x)}$ }
23:    end if
24:  end if
25: end for
26: Apskaičiuoti  $\mu_5, \sigma_5$  iš rezultatai5
27: Apskaičiuoti  $\mu_{12}, \sigma_{12}$  iš rezultatai12
28:  $C \leftarrow N_{\text{prog}} / N_{\text{viso}} \times 100\%$ 
29: return  $\mu_5, \sigma_5, \mu_{12}, \sigma_{12}, C$ 
```

Algoritmas kiekvienai valandai t formuoja įvesties langą x , ieško kaimynų istoriniuose duomenyse pagal slenksčio sąlygą $D(x, y) \leq S$ ir jei randa kaimynų, skaičiuoja prognozę bei jos paklaidas. Galiausiai gaunamos penkios suvestinės metrikos – vidurkiai ir standartiniai nuokrypiai 5 bei 12 valandų langams ir padengimas. Šios metrikos leidžia kompleksiskai įvertinti modelio kokybę: ne tik vidutinę paklaidą, bet ir jos kintamumą bei modelio gebėjimą pateikti prognozę.